

CC3104 – Aprendizaje por Refuerzo

Laboratorio 1

Instrucciones

- Esta es una actividad en grupos de no más de 4 integrantes.
 - Recuerden **unirse al grupo de canvas**
- No se permitirá ni se aceptará cualquier indicio de copia. De presentarse, se procederá según el reglamento correspondiente.
- Tendrán hasta el día indicado en Canvas.
 - No se confíen, aprovechen el tiempo en clase para entender todos los ejercicios y avanzar lo más posible.
- **NOTA:** Limiten el uso de IA generativa. Intenten primero buscar en fuentes de internet y si en verdad necesitan usarla, asegúrense de **colcar el prompt** que utilizan para cada task donde corresponda, así como una explicación de por qué ese prompt funcionó.

Una empresa de logística urbana opera una flota de drones de reparto en una ciudad modelada como una cuadrícula de 5x5. Cada drone parte de una base central, debe entregar paquetes en puntos designados y regresar. La empresa quiere entender si es posible modelar este problema de despacho como un MDP antes de invertir en un sistema de RL completo.

Su grupo ha sido contratado como equipo de consultoría técnica para diseñar y analizar el MDP que representa este problema, implementar un evaluador de políticas desde cero, y producir un reporte técnico con conclusiones accionables.

Task 1 (Entrega Parcial)

Dado el contexto de la empresa de logística, diseñen formalmente el MDP que modela el problema. Su diseño debe especificar con precisión y justificación:

1. El espacio de estados $\mathcal{S}$: ¿qué información debe contener el estado para que la propiedad de Markov se satisfaga razonablemente? Justifiquen cada variable que incluyen y cada variable que deciden omitir. Si omiten algo que podría ser relevante, expliquen qué consecuencia tiene esa omisión sobre la validez del modelo.
2. El espacio de acciones $\mathcal{A}$: definan las acciones disponibles para el drone. ¿Es discreto o continuo? ¿Hay acciones que deberían restringirse en ciertos estados? ¿Cómo modelan esa restricción dentro del MDP?
3. La función de recompensa $r(s, a, s')$: diseñen una función de recompensa que capture el objetivo real de la empresa. Consideren al menos tres objetivos potencialmente conflictivos: eficiencia de entrega, consumo de batería y seguridad de vuelo. ¿Cómo ponderan esos objetivos? ¿Qué consecuencias tendría una ponderación incorrecta sobre el comportamiento del agente?
4. La función de transición $p(s' | s, a)$: ¿es determinista o estocástica? Si es estocástica, ¿qué fuentes de aleatoriedad existen en el dominio real y cómo las modelan? Escriban al menos tres transiciones concretas con sus probabilidades y justifiquen cada valor.
5. El factor de descuento γ : propongan un valor y justifíquelo en términos del problema, no solo en términos matemáticos.



Task 2 (Entrega Parcial)

Respondan las siguientes preguntas con argumentación técnica

1. Identifiquen al menos dos situaciones en las que la propiedad de Markov se violaría con su representación de estado actual. Para cada una, propongan una extensión del estado que restaure la propiedad y discutan el costo computacional de esa extensión.
2. En el dominio de logística urbana, ¿qué tan razonable es el supuesto de que el agente puede observar el estado completo? ¿Qué variables del estado real probablemente no son directamente observables por el drone? ¿Cómo afecta eso la validez del modelo MDP versus un modelo POMDP?
3. Argumenten si este problema debería modelarse como una tarea episódica o continua. ¿Cómo cambia esa decisión el diseño de la función de recompensa y el valor de γ ?

Task 3 (Entrega Final)

Implementen en Python un evaluador iterativo de políticas para un GridWorld 5x5 que represente la ciudad de drones. Su implementación debe:

- Representar el MDP completo: estados, acciones, función de transición y función de recompensa, consistentes con el diseño de la Tarea 1. No usen librerías de RL como Gymnasium. El MDP debe estar implementado desde cero.
- Implementar la evaluación iterativa de políticas mediante aplicación repetida del operador de Bellman hasta convergencia. El criterio de convergencia debe ser configurable: el algoritmo termina cuando el cambio máximo en cualquier valor de estado entre dos iteraciones consecutivas es menor que un umbral θ .
- Evaluar y comparar al menos tres políticas distintas: la política uniforme aleatoria, una política determinista fija definida por ustedes, y la política greedy derivada de los valores de la política anterior.
- Producir para cada política evaluada: una tabla de valores $V^\pi(s)$ para todos los estados, el número de iteraciones hasta convergencia, y una visualización del grid con los valores codificados en color y las acciones de la política greedy superpuestas como flechas.

Task 4 (Entrega Final)

Con base en los resultados de la implementación, redacten un dictamen técnico dirigido a la gerencia de la empresa de logística. El dictamen debe:

1. Comparar cuantitativamente las tres políticas evaluadas. ¿Cuál produce los valores más altos? ¿En qué estados difieren más? ¿La política greedy derivada de la política aleatoria es mejor que la política determinista que diseñaron manualmente?
2. Analizar la sensibilidad del resultado al valor de γ que propusieron en la Tarea 1. Repitan la evaluación con al menos dos valores adicionales de γ y discutan cómo cambian los valores y la política greedy resultante.
3. Identificar las limitaciones del modelo que implementaron respecto al problema real. ¿Qué aspectos del dominio de logística urbana no puede capturar este MDP? ¿Qué extensiones serían necesarias para que el modelo sea operacionalmente útil?



- 
4. Concluir con una recomendación concreta: ¿es el MDP que diseñaron una base suficiente para construir un sistema de RL real para esta empresa? ¿Qué pasos siguientes recomendarían antes de proceder con la implementación completa?

Entregas en Canvas

1. Documento PDF con las respuestas a cada task
2. En la entrega parcial se espera que entreguen lo **señalado**, En la entrega final deben entregar **TODOS LOS TASK**
3. Archivo .ipynb, o link a repositorio de GitHub (**No se acepta entregas en otros medios**)
 - a. El código debe estar comentado explicando la relación con las fórmulas de las diapositivas.

Evaluación

1. [0.75 pt] Task 1
2. [0.60 pt] Task 2
3. [0.90 pt] Task 3
4. [0.75 pt] Task 5

Total: 3.0 pts