

CC3104 – Aprendizaje por Refuerzo

Laboratorio 2

Instrucciones

- Esta es una actividad en grupos de no más de 4 integrantes.
 - Recuerden **unirse al grupo de canvas**
- No se permitirá ni se aceptará cualquier indicio de copia. De presentarse, se procederá según el reglamento correspondiente.
- Tendrán hasta el día indicado en Canvas.
 - No se confíen, aprovechen el tiempo en clase para entender todos los ejercicios y avanzar lo más posible.
- **NOTA:** Limiten el uso de IA generativa. Intenten primero buscar en fuentes de internet y si en verdad necesitan usarla, asegúrense de **colcar el prompt** que utilizan para cada task donde corresponda, así como una explicación de por qué ese prompt funcionó.

Una empresa de gestión de infraestructura hospitalaria opera un sistema de ascensores en un edificio de cinco pisos. En horas críticas, el tiempo de espera de camillas y personal médico tiene consecuencias directas sobre la atención al paciente. La gerencia quiere optimizar la política de despacho de ascensores usando Programación Dinámica antes de comprometer presupuesto en un sistema de aprendizaje completo.

Su grupo ha sido contratado para modelar el problema como un MDP, implementar Policy Iteration y Value Iteration desde cero, comparar su comportamiento, y producir un dictamen técnico con recomendaciones concretas para la gerencia.

Task 1 (Entrega Parcial)

Dado el contexto del sistema de ascensores, diseñen formalmente el MDP que representa el problema. El diseño debe especificar con precisión y justificación:

1. El espacio de estados $\mathcal{S}$: ¿qué variables definen completamente la situación del sistema en un instante dado? Justifiquen cada variable incluida y cada variable omitida. Para cada variable omitida, argumenten qué supuesto están haciendo y qué consecuencia tiene ese supuesto sobre la validez del modelo.
2. El espacio de acciones $\mathcal{A}$: definan las acciones disponibles para el sistema de control. Argumenten si el espacio debe ser discreto o continuo para este dominio, y si existen acciones que deben restringirse en ciertos estados y cómo se modela esa restricción.
3. La función de recompensa $r(s, a, s')$: diseñen una función que capture el objetivo operacional real. Consideren al menos los siguientes objetivos potencialmente conflictivos: minimizar tiempo de espera promedio, priorizar pisos de emergencia, y minimizar consumo energético. Argumenten cómo ponderan esos objetivos y qué consecuencias tendría una ponderación incorrecta sobre el comportamiento del agente.
4. La función de transición $p(s' | s, a)$: argumenten si el entorno es determinista o estocástico. Si es estocástico, identifiquen las fuentes de aleatoriedad y escriban al menos cuatro transiciones concretas con sus probabilidades justificadas.
5. El factor de descuento γ : propongan un valor y justifiquenlo en términos del dominio, no solo matemáticamente. ¿Cómo cambia la política óptima si γ es cercano a 0 versus cercano a 1 en este contexto específico?



Task 2 (Entrega Parcial)

Respondan las siguientes preguntas con argumentación técnica

1. Para el MDP que diseñaron, ¿cuántas políticas deterministas posibles existen? Calculen el valor exacto y argumenten por qué la enumeración exhaustiva es inviable incluso para este problema relativamente pequeño.
2. Dado que $\mathcal{T}^\pi$ es una contracción con factor γ , ¿cuántas iteraciones de Policy Evaluation necesitan teóricamente para reducir el error inicial a menos de $\theta = 0.01$, asumiendo un error inicial de $\|V_0 - V^\pi\|_\infty \leq \frac{R_{\max}}{1-\gamma}$? Desarrollen el cálculo usando la cota de convergencia geométrica y el valor de γ que propusieron.
3. Para su MDP específico, ¿anticipan que Policy Iteration o Value Iteration convergerá más rápido en términos de tiempo de cómputo total? Justifiquen su respuesta considerando el tamaño del espacio de estados, el número de acciones, y el trade-off entre costo por iteración y número de iteraciones hasta convergencia.

Task 3 (Entrega Final)

Implementen en Python Policy Iteration y Value Iteration para un MDP de ascensor simplificado con las siguientes especificaciones fijas, independientemente del diseño de la Task 1:

- Edificio de 5 pisos, ascensor en uno de los pisos en cada instante
- Estado: par (p, d) donde $p \in \{1, 2, 3, 4, 5\}$ es el piso actual y $d \in \{0, 1\}$ indica si hay demanda pendiente en algún piso distinto al actual
- Acciones: subir un piso, bajar un piso, permanecer
- Transición determinista: subir desde el piso 5 permanece en 5, bajar desde el piso 1 permanece en 1
- Recompensa: -1 por cada paso sin atender demanda, $+10$ al atender demanda, -0.5 por movimiento innecesario en ausencia de demanda
- $\gamma = 0.95$, $\theta = 10^{-6}$.

Su implementación debe:

- Representar el MDP completo como estructuras de datos explícitas: tabla de transiciones y tabla de recompensas. No usar librerías de RL.
- Implementar Policy Evaluation como función separada reutilizable por Policy Iteration.
- Implementar Policy Iteration completo registrando el número de iteraciones externas hasta convergencia y el número total de aplicaciones del operador de Bellman.
- Implementar Value Iteration registrando el número de iteraciones hasta convergencia.
- Producir para cada algoritmo: la tabla de valores $V^*(s)$ para todos los estados, la política óptima $\pi^*(s)$ para todos los estados, el número de iteraciones hasta convergencia, y el tiempo de ejecución medido con `time.perf_counter`.





Task 4 (Entrega Final)

Con base en los resultados de la implementación, produzcan un dictamen técnico que incluya:

1. Verificación de consistencia: comprueben que las políticas óptimas producidas por Policy Iteration y Value Iteration son idénticas. Si difieren en algún estado, expliquen por qué puede ocurrir eso y cómo resolverlo. Si son idénticas, interpreten en lenguaje operacional qué le está diciendo la política óptima al sistema de control del ascensor.
2. Análisis de convergencia: comparen el número de iteraciones y el tiempo de ejecución de ambos algoritmos. ¿El resultado coincide con la predicción teórica que hicieron en la Tarea 2? Si no coincide, identifiquen la fuente de la discrepancia.
3. Análisis de sensibilidad a γ : repitan ambos algoritmos con $\gamma \in \{0.5, 0.75, 0.99\}$. Grafiquen el valor $V^*(s_0)$ del estado inicial en función de γ para ambos algoritmos. ¿Cómo cambia la política óptima? ¿En qué valor de γ cambia cualitativamente el comportamiento del ascensor?
4. Conexión con el diseño propio: comparen la política óptima obtenida para el MDP simplificado con el comportamiento que esperarían del MDP que diseñaron en la Tarea 1. ¿Qué aspectos del problema real no captura el MDP simplificado? ¿Cómo afectaría eso a la política óptima en el dominio real?
5. Dictamen final: redacten un párrafo dirigido a la gerencia del hospital argumentando si Programación Dinámica es una solución viable para el sistema de ascensores real, cuáles son sus limitaciones principales, y qué metodología recomendarían como paso siguiente.

Entregas en Canvas

1. Documento PDF con las respuestas a cada task
2. En la entrega parcial se espera que entreguen lo **señalado**, En la entrega final deben entregar **TODOS LOS TASK**
3. Archivo .ipynb, o link a repositorio de GitHub (**No se acepta entregas en otros medios**)
 - a. El código debe estar comentado explicando la relación con las fórmulas de las diapositivas.

Evaluación

1. [0.60 pt] Task 1
2. [0.60 pt] Task 2
3. [0.90 pt] Task 3
4. [0.90 pt] Task 5

Total: 3.0 pts

