

CC3104 – Aprendizaje por Refuerzo

Laboratorio 3

Instrucciones

- Esta es una actividad en grupos de no más de 4 integrantes.
 - Recuerden **unirse al grupo de canvas**
- No se permitirá ni se aceptará cualquier indicio de copia. De presentarse, se procederá según el reglamento correspondiente.
- Tendrán hasta el día indicado en Canvas.
 - No se confíen, aprovechen el tiempo en clase para entender todos los ejercicios y avanzar lo más posible.
- **NOTA:** Limiten el uso de IA generativa. Intenten primero buscar en fuentes de internet y si en verdad necesitan usarla, asegúrense de **colcar el prompt** que utilizan para cada task donde corresponda, así como una explicación de por qué ese prompt funcionó.

Una empresa de desarrollo de videojuegos está evaluando el uso de agentes de RL para generar comportamiento no determinista en personajes de un juego de rol táctico. El entorno de prueba es un mapa de cuadrícula de 6×6 con zonas de recompensa, zonas de penalización y un estado terminal. El equipo técnico necesita entender si Monte Carlo es viable para este dominio antes de escalar a métodos más complejos, y quiere comparar su comportamiento contra la línea base de Programación Dinámica de la semana anterior.

Su grupo ha sido contratado para diseñar el experimento, implementar los métodos, analizar los resultados, y producir un reporte técnico con recomendaciones sobre la viabilidad de Monte Carlo para este dominio.

Task 1 (Entrega Parcial)

Antes de implementar nada, diseñen formalmente el experimento que van a ejecutar. El diseño debe incluir:

1. Especificación del MDP: definan el espacio de estados, el espacio de acciones, la función de recompensa y el factor de descuento γ para el mapa 6×6 . Justifiquen cada decisión de diseño. El mapa debe incluir al menos dos zonas de recompensa positiva, una zona de penalización, y un estado terminal. La función de recompensa debe capturar al menos dos objetivos potencialmente conflictivos propios del dominio de videojuegos.
2. Selección de variante Monte Carlo: argumenten cuál variante usarán, First-Visit o Every-Visit, y por qué es más apropiada para este dominio específico. Incluyan en su argumento una discusión sobre la frecuencia esperada de visitas a estados en un mapa 6×6 bajo una política aleatoria.
3. Estrategia de exploración: argumenten si usarán Exploring Starts o política ϵ -soft. Justifiquen su elección considerando si en el dominio de videojuegos es razonable controlar el estado inicial del agente. Propongan un valor concreto de ϵ si eligen política ϵ -soft, con justificación.
4. Hipótesis de comparación: antes de ejecutar el experimento, formulen al menos dos hipótesis concretas sobre cómo esperan que se comporte Monte Carlo en comparación con Value Iteration de la semana pasada. Las hipótesis deben ser falsables y cuantificables.



Task 2 (Entrega Parcial)

Respondan las siguientes preguntas con argumentación técnica

1. Para el MDP que diseñaron, calculen una cota superior del número de episodios necesarios para que todos los pares (s, a) sean visitados al menos una vez en esperanza, bajo una política uniforme aleatoria. Expresen el resultado en función de $|\mathcal{S}|$ y $|\mathcal{A}|$ y evalúen numéricamente para su MDP específico.
2. El retorno G_t es un estimador insesgado pero de alta varianza de $V^\pi(s)$. Expliquen formalmente de dónde proviene esa varianza, por qué crece con la longitud del episodio, y qué consecuencia tiene sobre el número de episodios necesarios para convergencia práctica.
3. Argumenten formalmente por qué Monte Carlo no puede aplicarse directamente a tareas continuas. Propongan una modificación concreta al algoritmo que permita aproximar Monte Carlo en una tarea continua, y discutan las implicaciones de esa modificación sobre las garantías de convergencia.

Task 3 (Entrega Final)

Implementen en Python First-Visit o Every-Visit Monte Carlo Control para el MDP diseñado en la Tarea 1. La implementación debe incluir:

- Representación explícita del entorno como clase con métodos `reset`, `step`, y `render`. No usar librerías de RL.
- Implementación de Monte Carlo Control con la variante y estrategia de exploración elegidas en la Tarea 1, con soporte para registrar el número de episodios hasta convergencia y la evolución de $Q(s, a)$ durante el entrenamiento.
- Criterio de convergencia explícito y justificado: definan cuándo consideran que Q ha convergido y por qué ese criterio es apropiado para Monte Carlo.
- Visualización del mapa con los valores $V(s) = \max_a Q(s, a)$ codificados en color y la política greedy superpuesta como flechas direccionales, para al menos tres puntos del entrenamiento: inicio, mitad, y convergencia.
- Comparación directa con Value Iteration: ejecuten Value Iteration sobre el mismo MDP y comparen las políticas óptimas resultantes. Si difieren en algún estado, argumenten por qué.

Task 4 (Entrega Final)

Con base en los resultados de la implementación, realice

1. Verificación de hipótesis: contrasten cada hipótesis formulada en la Tarea 1 con los resultados observados. Para cada hipótesis, indiquen si fue confirmada, refutada, o si los resultados son inconclusos, y expliquen por qué.
2. Análisis de convergencia: grafiquen la evolución de $\|Q_k - Q^*\|_\infty$ en función del número de episodios, donde Q^* se aproxima con la solución de Value Iteration. ¿La convergencia es monótona? ¿Qué factores del diseño del MDP o del algoritmo afectan la velocidad de convergencia?
3. Sensibilidad a ε : repitan el experimento con al menos tres valores distintos de ε . Grafiquen el retorno promedio por episodio en función del número de episodios para cada valor. ¿Existe un valor



de ϵ que domine a los demás en este dominio? ¿Ese resultado generaliza o depende del MDP específico?

4. Investigación bibliográfica: busquen y lean un paper publicado entre 2020 y 2025 que aplique métodos Monte Carlo o sus extensiones a un problema real. El paper debe ser de una fuente indexada: NeurIPS, ICML, ICLR, JMLR, o similar. Escriban un resumen técnico de media página que incluya: el problema que resuelve, cómo aplica o extiende Monte Carlo, los resultados principales, y una reflexión sobre qué limitaciones de Monte Carlo clásico que discutimos esta semana resuelve o no resuelve ese trabajo.
5. Dictamen técnico: redacten un párrafo dirigido al equipo directivo de la empresa de videojuegos argumentando si Monte Carlo es una solución viable para generar comportamiento de personajes en el dominio descrito, cuáles son sus limitaciones principales en ese contexto específico, y qué metodología recomendarían como paso siguiente considerando lo que saben sobre Temporal-Difference Learning.

Entregas en Canvas

1. Documento PDF con las respuestas a cada task
2. En la entrega parcial se espera que entreguen lo **señalado**, En la entrega final deben entregar **TODOS LOS TASK**
3. Archivo .ipynb, o link a repositorio de GitHub (**No se acepta entregas en otros medios**)
 - a. El código debe estar comentado explicando la relación con las fórmulas de las diapositivas.

Evaluación

1. [0.60 pt] Task 1
2. [0.60 pt] Task 2
3. [0.90 pt] Task 3
4. [0.90 pt] Task 5

Total: 3.0 pts