

CC3104 – Aprendizaje por Refuerzo

Laboratorio 4

Instrucciones

- Esta es una actividad en grupos de no más de 4 integrantes.
 - Recuerden **unirse al grupo de canvas**
- No se permitirá ni se aceptará cualquier indicio de copia. De presentarse, se procederá según el reglamento correspondiente.
- Tendrán hasta el día indicado en Canvas.
 - No se confíen, aprovechen el tiempo en clase para entender todos los ejercicios y avanzar lo más posible.
- **NOTA:** Limiten el uso de IA generativa. Intenten primero buscar en fuentes de internet y si en verdad necesitan usarla, asegúrense de **colcar el prompt** que utilizan para cada task donde corresponda, así como una explicación de por qué ese prompt funcionó.

Una empresa de logística de última milla está evaluando el uso de robots autónomos para la gestión interna de su almacén principal. El almacén se modela como una cuadrícula de 8×8 con puntos de recogida, puntos de entrega, zonas de penalización por congestión, y obstáculos fijos. El equipo de ingeniería necesita comparar dos estrategias de aprendizaje antes de comprometer recursos en un sistema completo: una política conservadora que aprenda a navegar de forma segura durante el entrenamiento, y una política agresiva que busque la ruta óptima sin importar los riesgos durante la exploración.

Su grupo ha sido contratado para implementar ambas estrategias usando SARSA y Q-Learning respectivamente, comparar su comportamiento empírico, y producir un dictamen técnico con recomendaciones concretas para la gerencia.

Task 1 (Entrega Parcial)

Diseñen formalmente el MDP que representa el almacén. El diseño debe especificar:

1. El espacio de estados y el espacio de acciones. Justifiquen cada decisión considerando la interfaz de Gymnasium: `observation_space` y `action_space` deben ser instancias de `gymnasium.spaces.Discrete` o `gymnasium.spaces.Box` según corresponda. Argumenten cuál es más apropiado para este dominio.
2. La función de recompensa con al menos tres componentes: recompensa por entrega exitosa, penalización por zona de congestión, y penalización por paso. Justifiquen la magnitud relativa de cada componente y argumenten qué comportamiento indeseable produciría una ponderación incorrecta de alguno de ellos.
3. La condición de terminación del episodio: ¿cuándo termina un episodio? ¿Es apropiado tener un límite máximo de pasos? Justifiquen.
4. El diseño del mapa 8×8 : ubiquen al menos dos zonas de congestión adyacentes a rutas de alta recompensa. Esta configuración específica es crítica para que la comparación entre SARSA y Q-Learning sea informativa. Expliquen por qué esa configuración espacial genera el comportamiento diferencial esperado entre ambos algoritmos..



Task 2 (Entrega Parcial)

Antes de implementar nada, respondan las siguientes preguntas con argumentación técnica:

1. Para el entorno que diseñaron, predigan formalmente cuál algoritmo, SARSA o Q-Learning, producirá mayor recompensa acumulada durante el entrenamiento y cuál producirá mayor recompensa durante la evaluación con política greedy pura. Justifiquen cada predicción usando las propiedades on-policy y off-policy de cada algoritmo y la estructura específica de su mapa.
2. Argumenten cómo afecta el valor de ϵ al comportamiento diferencial entre SARSA y Q-Learning en su entorno. ¿Existe un valor de ϵ para el cual ambos algoritmos convergen a políticas idénticas? Justifiquen matemáticamente.
3. Para su función de recompensa específica, calculen una cota superior del valor óptimo $V^*(s_0)$ del estado inicial, asumiendo que el agente siempre toma la ruta más corta sin pasar por zonas de congestión. Usen esta cota como referencia para evaluar qué tan cerca llegan sus implementaciones al óptimo teórico.

Task 3 (Entrega Final)

Implementen el entorno y los algoritmos con las siguientes especificaciones:

El entorno debe implementarse como una clase `WarehouseEnv` que herede de `gymnasium.Env`, con los métodos `reset`, `step`, y `render` correctamente implementados según la interfaz estándar de `Gymnasium`. El método `render` debe producir una visualización en consola o `matplotlib` del estado actual del agente en el mapa.

Los algoritmos SARSA y Q-Learning deben implementarse desde cero como funciones o clases separadas que reciban el entorno como argumento y devuelvan la tabla Q aprendida y el historial de recompensas por episodio. No se permite usar implementaciones preconstruidas de SARSA o Q-Learning de ninguna librería.

La implementación debe registrar para cada episodio: la recompensa total acumulada, el número de pasos hasta terminación, y el número de veces que el agente pasó por zonas de congestión. Estos registros son necesarios para el análisis de la Tarea 4.

Al finalizar el entrenamiento, evalúen cada política aprendida con 100 episodios usando política greedy pura, sin exploración, y registren las mismas métricas.

Task 4 (Entrega Final)

Con base en lo aprendido, responda

1. **Verificación de predicciones:** contrasten cada predicción de la Tarea 2 con los resultados observados. Para cada predicción indiquen si fue confirmada, refutada o inconclusa, y expliquen la discrepancia si la hay. Una predicción refutada con buena explicación vale más que una confirmada sin análisis.
2. **Análisis de convergencia y comportamiento diferencial:** grafiquen la recompensa promedio por episodio durante el entrenamiento para ambos algoritmos en la misma figura. Grafiquen también el número promedio de visitas a zonas de congestión por episodio. ¿En qué punto del entrenamiento se hace visible la diferencia entre SARSA y Q-Learning? ¿Coincide con lo esperado teóricamente?



3. **Análisis de sensibilidad:** repitan el experimento con al menos tres combinaciones de (α, ϵ) . Para cada combinación reporten la recompensa promedio en evaluación greedy. Construyan una tabla comparativa y argumenten cuál combinación recomendarían para producción y por qué.
4. **Investigación bibliográfica:** busquen y lean un paper publicado entre 2021 y 2025 que aplique Q-Learning, SARSA, o alguna extensión directa de TD Learning a un problema de navegación, robótica, o logística. El paper debe ser de una fuente indexada: NeurIPS, ICML, ICLR, JMLR, IEEE Robotics, o similar. Escriban un resumen técnico de media página que incluya: el problema que resuelve, cómo extiende o aplica TD Learning, los resultados principales, y una reflexión sobre qué limitaciones del TD tabular que discutimos esta semana resuelve ese trabajo y cuáles no.
5. **Dictamen técnico:** redacten un párrafo dirigido a la gerencia del almacén argumentando cuál de los dos algoritmos recomiendan para el sistema real, bajo qué condiciones operativas, y qué pasos adicionales serían necesarios antes de un despliegue en producción. El dictamen debe estar respaldado por evidencia de sus experimentos, no solo por argumentos teóricos.

Entregas en Canvas

1. Documento PDF con las respuestas a cada task
2. En la entrega parcial se espera que entreguen lo **señalado**, En la entrega final deben entregar **TODOS LOS TASK**
3. Archivo .ipynb, o link a repositorio de GitHub (**No se acepta entregas en otros medios**)
 - a. El código debe estar comentado explicando la relación con las fórmulas de las diapositivas.

Evaluación

1. [0.60 pt] Task 1
2. [0.60 pt] Task 2
3. [0.90 pt] Task 3
4. [0.90 pt] Task 5

Total: 3.0 pts