

CC3104 – Aprendizaje por Refuerzo

Laboratorio 6

Instrucciones

- Esta es una actividad en grupos de no más de 4 integrantes.
 - Recuerden **unirse al grupo de canvas**
- No se permitirá ni se aceptará cualquier indicio de copia. De presentarse, se procederá según el reglamento correspondiente.
- Tendrán hasta el día indicado en Canvas.
 - No se confíen, aprovechen el tiempo en clase para entender todos los ejercicios y avanzar lo más posible.
- **NOTA:** Limiten el uso de IA generativa. Intenten primero buscar en fuentes de internet y si en verdad necesitan usarla, asegúrense de **colcar el prompt** que utilizan para cada task donde corresponda, así como una explicación de por qué ese prompt funcionó.

Una empresa de robótica de asistencia médica está desarrollando un exoesqueleto para rehabilitación de movilidad en pacientes con lesiones de rodilla. El sistema de control debe aprender a asistir el movimiento de la pierna del paciente de forma suave y eficiente, minimizando el esfuerzo del motor y maximizando la fluidez del movimiento. Antes de trabajar con el hardware real, el equipo de ingeniería necesita validar si los métodos de gradiente de política son apropiados para este dominio de control continuo, usando entornos de simulación estándar como proxy del problema real.

Su grupo ha sido contratado para implementar y comparar REINFORCE con línea base y un Actor-Critic simple, analizar sus propiedades de convergencia, e investigar el estado del arte en control de exoesqueletos con RL para producir un dictamen técnico fundamentado.

Task 1 (Entrega Parcial)

Respondan las siguientes preguntas con argumentación técnica rigurosa antes de implementar nada:

1. El entorno de simulación que usarán es LunarLanderContinuous-v2 de Gymnasium, que tiene un espacio de acción continuo de dos dimensiones representando la fuerza de dos propulsores. Argumenten formalmente por qué Q-Learning tabular y DQN son inapropiados para este entorno. Su argumento debe mencionar explícitamente el espacio de acción, el operador $\arg\max$, y la representación de la política.
2. Para LunarLanderContinuous-v2, la política se parametrizará como una distribución Gaussiana $\pi_{\theta}(a | s) = \mathcal{N}(\mu_{\theta}(s), \sigma^2 I)$ donde $\mu_{\theta}(s)$ es la salida de una red neuronal. Expliquen cómo se calcula $\nabla_{\theta} \ln \pi_{\theta}(A_t | S_t)$ para esta parametrización específica. Desarrollen la expresión analítica del gradiente del logaritmo de la densidad Gaussiana respecto a θ , identificando qué parte depende de θ y qué parte no.
3. Comparen formalmente REINFORCE con línea base y Actor-Critic en términos de sesgo y varianza del estimador del gradiente. Para cada algoritmo identifiquen: qué usa como estimador de la ventaja $\hat{A}_t$, qué componente introduce sesgo, y qué componente introduce varianza. Predigan cuál algoritmo esperan que converja más rápido en LunarLanderContinuous-v2 y justifiquen esa predicción.
4. El entorno de exoesqueleto real tiene una restricción que LunarLanderContinuous-v2 no tiene: las acciones deben ser suaves en el tiempo para no causar movimientos bruscos que dañen al paciente. Argumenten cómo modificarían la función de recompensa y la parametrización de la política para incorporar esa restricción. ¿Cambiaría eso la elección entre REINFORCE y Actor-Critic?



Task 2 (Entrega Final)

Implementen REINFORCE con línea base y Actor-Critic sobre LunarLanderContinuous-v2 con las siguientes especificaciones.

Ambos algoritmos deben usar una red neuronal con dos capas ocultas de 64 neuronas y activaciones ReLU para parametrizar la política. La media $\mu_\theta(s)$ es la salida de la red con activación tanh para restringir las acciones al rango válido. La desviación estándar σ debe ser un parámetro aprendible independiente del estado, inicializado en 0.5. Para REINFORCE, la línea base debe ser una red separada que aproxime $V^\pi(s)$, entrenada con pérdida cuadrática sobre los retornos observados. Para Actor-Critic, el Critic comparte el cuerpo de la red con el Actor y tiene una cabeza de salida escalar para $\hat{V}_w(s)$.

La implementación debe incluir:

- Ambos algoritmos implementados desde cero usando PyTorch para la diferenciación automática. No se permite usar implementaciones preconstruidas de REINFORCE o Actor-Critic de ninguna librería de RL.
- Registro por episodio de recompensa total, norma del gradiente del Actor $\|\nabla_\theta L\|$, y entropía de la política $S[\pi_\theta]$.
- Entrenamiento de ambos algoritmos durante al menos 1000 episodios con la misma semilla aleatoria para comparación justa.
- Cuatro gráficas: curvas de aprendizaje de ambos algoritmos en la misma figura con media móvil de 20 episodios, evolución de la norma del gradiente, evolución de la entropía de la política, y una visualización de al menos un episodio de la política aprendida mediante `env.render()`.

Task 3 (Entrega Final)

Con base en los resultados de la implementación y en investigación bibliográfica, ralicen lo siguiente:

1. Contrasten cada predicción de la Tarea 1 con los resultados observados. Para cada predicción indiquen si fue confirmada, refutada o inconclusa. Una predicción refutada con buena explicación de la discrepancia vale más que una confirmada sin análisis.
2. La norma $\|\nabla_\theta L\|$ durante el entrenamiento es un indicador de estabilidad. Describan su evolución para ambos algoritmos. ¿Hay episodios donde la norma es anormalmente alta? ¿Coinciden con caídas en la recompensa? ¿Qué implicación tiene eso sobre el problema de los pasos grandes que motivó PPO?
3. La entropía de la política debería decrecer gradualmente durante el entrenamiento a medida que la política se vuelve más determinista. ¿Observan ese comportamiento? ¿En qué punto del entrenamiento la entropía cae más rápido? ¿Qué consecuencia tendría agregar un término de entropía en la pérdida como hace PPO?
4. Busquen y lean un paper publicado entre 2022 y 2025 que aplique métodos de gradiente de política, Actor-Critic, PPO o una extensión directa de estos algoritmos a control de exoesqueletos, prótesis robóticas, rehabilitación médica, o asistencia de movilidad. El paper debe ser de IEEE Transactions on Neural Systems and Rehabilitation Engineering, Nature Machine Intelligence, NeurIPS, ICML, o similar. Escriban un resumen técnico de media página que incluya: el problema que resuelve, qué algoritmo de gradiente de política usa y por qué, los resultados principales, y una reflexión sobre qué limitaciones de REINFORCE y Actor-Critic que observaron en sus experimentos resuelve ese trabajo y cuáles persisten.



- 
5. Redacten dos párrafos dirigidos al equipo directivo de la empresa de exoesqueletos. El primero debe argumentar si REINFORCE o Actor-Critic es más apropiado como punto de partida para el sistema real, con evidencia de sus experimentos. El segundo debe argumentar si recomiendan escalar directamente a PPO antes del despliegue en hardware, considerando las limitaciones de suavidad de acción identificadas en la Tarea 1 y los resultados de la investigación bibliográfica.

NOTAS A CONSIDERAR:

1. Dependencias permitidas: gymnasium, numpy, matplotlib, torch. No se permiten implementaciones preconstruidas de REINFORCE, Actor-Critic o PPO de librerías de RL.
2. Instalar el entorno con: `pip install gymnasium[box2d]`.
3. El paper debe citarse correctamente con autores, título, venue y año. Incluyan DOI o enlace arXiv.
4. No se aceptan entregas tardías sin justificación enviada previamente al correo del curso.

Entregas en Canvas

1. Documento PDF con las respuestas a cada task
2. En la entrega parcial se espera que entreguen lo **señalado**, En la entrega final deben entregar **TODOS LOS TASK**
3. Archivo .ipynb, o link a repositorio de GitHub (**No se acepta entregas en otros medios**)
 - a. El código debe estar comentado explicando la relación con las fórmulas de las diapositivas.

Evaluación

1. [1.50 pt] Task 1
2. [0.75 pt] Task 2
3. [0.75 pt] Task 3

Total: 3.0 pts