

## CC3104 – Reinforcement Learning

# Laboratorio 7

### Instrucciones

- Esta es una actividad en grupos de no más de 5 integrantes.
  - Recuerden **unirse al grupo de canvas**
- No se permitirá ni se aceptará cualquier indicio de copia. De presentarse, se procederá según el reglamento correspondiente.
- Tendrán hasta el día indicado en Canvas.
  - No se confíen, aprovechen el tiempo en clase para entender todos los ejercicios y avanzar lo más posible.
- **NOTA:** Limiten el uso de IA generativa. Intenten primero buscar en fuentes de internet y si en verdad necesitan usarla, asegúrense de **colocar el prompt** que utilizan para cada task donde corresponda, así como una explicación de por qué ese prompt funcionó.

Una empresa de ciberseguridad opera un sistema de detección de intrusiones en redes corporativas. El sistema monitorea el tráfico de red en tiempo real y debe decidir qué acciones tomar ante comportamientos sospechosos: ignorar, alertar, bloquear temporalmente, o aislar el segmento afectado. El estado del sistema en cada instante es un vector de alta dimensión que incluye métricas de tráfico, patrones de comportamiento de usuarios, y logs de eventos recientes. La empresa quiere explorar si Deep RL puede mejorar la toma de decisiones frente a los sistemas basados en reglas que usan actualmente.

### Task 1 (Entrega Parcial)

#### Task 1.1

El equipo de ingeniería propone usar DQN estándar para este sistema. Antes de implementar cualquier cosa, usted debe hacer un análisis crítico de esa propuesta.

- a. El estado del sistema es un vector de 256 dimensiones con valores continuos. Argumenten si DQN es arquitecturalmente apropiado para este tipo de estado. ¿Qué tipo de red usarían como aproximador de  $Q(s, a; \mathbf{w})$  y por qué, considerando que el estado no es una imagen sino un vector numérico?
- b. El espacio de acciones tiene 4 opciones discretas. Argumenten si DQN o alguna de sus variantes es apropiado para este espacio de acciones, o si sería necesario un algoritmo diferente.
- c. En el dominio de detección de intrusiones, los eventos críticos (intrusiones reales) son extremadamente raros: ocurren en menos del 0.1% de los pasos de tiempo. Argumenten formalmente qué consecuencia tiene esa rareza sobre el buffer de Experience Replay y sobre la distribución de muestreo uniforme. ¿Qué variante de DQN resolvería este problema específico y cómo?
- d. El sistema actual basado en reglas tiene una tasa de falsos positivos del 8%. Si diseñaran la función de recompensa de DQN para minimizar falsos positivos únicamente, ¿qué comportamiento indeseable podría aprender el agente? Diseñen una función de recompensa con al menos tres componentes que capture el objetivo real del sistema, justificando la magnitud relativa de cada uno.

#### Task 1.2

El equipo propone usar Double DQN en lugar de DQN estándar.

- a. Expliquen formalmente el problema de sobreestimación que Double DQN resuelve. En el contexto específico de detección de intrusiones, ¿qué consecuencia operacional tendría que el agente sobreestime sistemáticamente el valor de la acción "bloquear"? ¿Y de la acción "ignorar"?

- b. Escriban la expresión del target de DQN estándar y la del target de Double DQN, identificando con precisión qué parámetros hacen qué en cada caso. ¿Cuál es el único cambio de implementación entre ambos?
- c. Argumenten si en este dominio específico la sobreestimación es un problema más grave en ciertos tipos de estados que en otros. Consideren estados con alta ambigüedad (tráfico borderline) versus estados claramente maliciosos.

## Task 2 (Entrega Final)

### Task 2.1

Implementen DQN y Double DQN sobre el entorno LunarLander-v2 de Gymnasium, que tiene espacio de acción discreto con 4 acciones y estado continuo de 8 dimensiones. Usen este entorno como proxy del sistema de detección de intrusiones para validar las propiedades algorítmicas antes de escalar al dominio real.

La red para  $Q(s, a; \mathbf{w})$  debe tener dos capas ocultas de 128 neuronas con activación ReLU. El buffer de Experience Replay debe tener capacidad de 50,000 transiciones. El minibatch debe ser de 64 transiciones. La Target Network debe actualizarse cada 500 pasos. Usen  $\epsilon$  decreciente de 1.0 a 0.05 durante los primeros 10,000 pasos.

Ambos algoritmos deben implementarse desde cero usando PyTorch. No se permite usar implementaciones preconstruidas de DQN de ninguna librería de RL.

La implementación debe registrar por episodio: recompensa total, valor Q promedio estimado sobre un conjunto fijo de 100 estados de evaluación, y el target promedio usado en las actualizaciones. Estos tres registros son necesarios para detectar sobreestimación.

### Task 2.2

Con base en los resultados de la implementación, respondan:

- a. Grafiquen la recompensa promedio por episodio de DQN y Double DQN en la misma figura con media móvil de 20 episodios. ¿Cuál converge más rápido? ¿Cuál alcanza mayor recompensa final? ¿El resultado coincide con lo esperado teóricamente?
- b. Grafiquen el valor Q promedio estimado durante el entrenamiento para ambos algoritmos. El valor Q de DQN debería ser sistemáticamente mayor que el de Double DQN sobre los mismos estados. ¿Observan ese patrón? Si no lo observan, argumenten por qué podría no ser visible en este entorno específico.
- c. Implementen ahora Prioritized Experience Replay sobre Double DQN, usando  $\alpha = 0.6$  y  $\beta$  creciente de 0.4 a 1.0. Comparen la velocidad de convergencia de Double DQN con muestreo uniforme versus Double DQN con PER. ¿En qué fase del entrenamiento es más visible la diferencia?
- d. Argumenten si PER sería más o menos beneficioso en el dominio real de detección de intrusiones comparado con LunarLander, considerando la rareza de los eventos críticos que analizaron en la Task 1.1c. Apoyen su argumento con evidencia de sus experimentos.

### Task 2.3

Investigación bibliográfica y dictamen técnico.

- a. Busquen y lean un paper publicado entre 2022 y 2025 que aplique DQN, Double DQN, Dueling DQN, PER, o Rainbow a un problema de ciberseguridad, detección de anomalías, o gestión de redes. El paper debe ser de IEEE Transactions on Information Forensics and Security, NeurIPS, ICML, USENIX Security, o similar. Escriban un resumen técnico de media página con: el problema que resuelve, qué

variante de DQN usa y por qué, los resultados principales, y una reflexión sobre si las limitaciones de DQN que identificaron en la Task 1 fueron resueltas en ese trabajo.

- b. Redacten un dictamen técnico de un párrafo dirigido al equipo directivo de la empresa de ciberseguridad. El dictamen debe argumentar si recomiendan proceder con DQN o alguna de sus variantes para el sistema de detección de intrusiones, qué variante específica recomiendan y por qué, y qué pasos adicionales serían necesarios antes de un despliegue en producción. El dictamen debe estar respaldado por evidencia de sus experimentos, no solo por argumentos teóricos.

### Entregas en Canvas

1. Documento PDF con las respuestas a cada task
1. En la entrega parcial se espera que entreguen lo **señalado**. En la entrega final deben entregar **TODOS LOS TASK**
2. Archivo .ipynb, o link a repositorio de GitHub (**No se acepta entregas en otros medios**)
  - a. El código debe estar comentado explicando la relación con las fórmulas de las diapositivas

### Evaluación

1. [1.20 pt] Task 1
2. [1.80 pt] Task 2

Total: 3.0 pts